

Cloude:

Clasificación de Dimensiones Emocionales mediante EEG en Adultos Mayores

Resumen del Estudio

Objetivo Principal: Este estudio se enfocó en la **clasificación de dimensiones emocionales** inducidas por **estímulos musicales en adultos mayores** mediante el análisis de señales de **electroencefalografía (EEG)** y técnicas de **aprendizaje automático**. El enfoque principal fue la **excitabilidad**, ya que la **clasificación de la valencia resultó compleja** debido a la escasez de datos.

Procesamiento de Señales: Se implementaron diversas etapas de procesamiento para optimizar las señales EEG, incluyendo el **filtrado para eliminar ruido** (normalización, eliminación de *offset* y ruido de red), la **extracción de 11 características** (diez aplicadas en tres segmentos para 30 constantes, y la asimetría generando 15 constantes adicionales) y la **selección de características relevantes** mediante pruebas estadísticas como Kolmogorov-Smirnov y Levene.

Etiquetado y Base de Datos: Las etiquetas de excitabilidad (alta o baja) se determinaron usando la prueba **Self-Assessment Manikin (SAM)** después de la exposición a estímulos musicales. La base de datos incluyó 7 ensayos de adultos mayores, aunque se aplicaron **criterios rigurosos de exclusión** y reorganización de datos para asegurar la calidad y robustez del conjunto final.

Modelado y Validación: Se utilizó un **modelo de clasificación de regresión logística**. El rendimiento se evaluó mediante **matrices de confusión** y el **área bajo la curva ROC**.

Resultados Clave: Los resultados del entrenamiento fueron prometedores, alcanzando una **precisión del 85.73% para características paramétricas** y del **88.31% para características no paramétricas**. En cuanto a la **asimetría no paramétrica**, la precisión fue del 57.39%. La capacidad discriminativa (Área bajo la curva ROC) fue del **92.66% para paramétricas** y **94.58% para no paramétricas**, y del **59.13% para asimetría no paramétrica**.

Procesamiento de Señales

El procesamiento de señales constituye un paso **fundamental para optimizar la extracción de características relevantes** y garantizar la fiabilidad del modelo de clasificación, ya que permite la identificación de patrones en las señales EEG y la eliminación de artefactos no relacionados con la actividad cerebral. Este proceso se divide en varias etapas:

1. Preprocesamiento (Filtrado para Eliminar Ruido)

El preprocesamiento es crucial porque las señales EEG pueden contener **ruidos y artefactos** que distorsionan los datos, como el parpadeo del paciente, la colocación incorrecta de electrodos, los latidos del corazón, y especialmente la **interferencia de la red eléctrica** (que puede ser de 50Hz o 60Hz). Para mitigar estos problemas, se aplicaron las siguientes técnicas de filtrado:

Normalización: Este proceso tiene como objetivo **estandarizar los datos** de la señal EEG y facilitar su interpretación. Se realiza identificando los valores **mínimos y máximos** de la señal, y luego escalando cada valor original a un rango predefinido mediante la siguiente fórmula:

$$N_i = \frac{X_i - X_{\min}}{X_{\max} - X_{\min}}$$

Donde N_i es el valor normalizado, X_i es el valor original, $X_{\min}$ es el valor mínimo y $X_{\max}$ es el valor máximo. Esto asegura la comparabilidad de los datos al eliminar las diferentes escalas presentes en las señales originales.

Referencia Común Promedio (CAR): El filtro CAR se utiliza principalmente para **optimizar la relación señal-ruido** en las señales EEG. Su propósito es **atenuar los artefactos comunes** a todas las derivaciones (como movimientos oculares o actividad muscular) y resaltar las señales de interés cerebral. En el contexto de este estudio, también se utilizó para **eliminar el offset** o desplazamiento constante observado en las señales originales. La ecuación para el cálculo de este filtro es:

$$V_{CARi} = V_{ERi} - \frac{1}{n} \sum_{j=1}^n V_{ERj}$$

Donde V_{CARi} es el potencial filtrado, V_{ERi} es el potencial entre el i -ésimo electrodo y la referencia, y n es el número de electrodos. La aplicación de CAR contribuye a la **centralización de la señal**, reduciendo la variabilidad entre electrodos y garantizando la coherencia de los resultados.

Filtro Notch: Este filtro digital está diseñado para **suprimir frecuencias de ruido específicas**, como la proveniente de la **red eléctrica (60Hz)**. El filtro Notch

identifica y cancela selectivamente esta frecuencia no deseada sin afectar el resto del espectro de la señal. En este trabajo, se basó en la función `iirnotch` de MATLAB, que genera los coeficientes del filtro para una frecuencia central (60 Hz) y un ancho de banda (0.8). Se aplica a la señal usando la función `filtfilt` para eliminar la fase, y su efecto se observa en el dominio de la frecuencia.

2. Extracción de Características

Una vez preprocesadas, las señales pasan por la etapa de extracción de características, que consiste en identificar los atributos más significativos de los datos brutos. Esto es esencial para **reducir la dimensionalidad** y **mejorar la eficiencia computacional** y la precisión del modelo. Se extrajeron 11 características: diez de ellas del dominio del tiempo y frecuencia, y una (asimetría) que tiene un comportamiento distinto. Para cada uno de los tres segmentos de la señal, se obtuvieron 30 constantes de las primeras 10 características y 15 constantes adicionales de la undécima característica (asimetría).

Las características consideradas incluyen:

Asimetría (AS): Evalúa las diferencias en la actividad eléctrica entre los hemisferios cerebrales (izquierdo y derecho) a través del índice de asimetría racional, derivado de la densidad espectral de potencia y el porcentaje de energía de la onda. Se calcula usando el logaritmo natural del cociente de la energía entre hemisferios. Proporciona 5 características adicionales.

Entropía Diferencial (E.D.): Mide el nivel de incertidumbre o caos en una variable aleatoria continua, cuantificando la complejidad de las señales EEG, asumiendo una aproximación a una distribución gaussiana.

Media (MD): El valor promedio de todas las amplitudes registradas en un período de tiempo.

Varianza (VAR): Mide la variabilidad o dispersión de un conjunto de números en relación con su media.

Desviación Estándar (D.E.): Indica cuán dispersos están los valores con respecto a la media, calculada como la raíz cuadrada de la varianza.

Sesgo (SES): Analiza la asimetría en la distribución de los valores de la señal, calculando la diferencia entre la media y la mediana.

Valores Máximos (V.MAX): El valor finito más grande dentro de la señal en un período dado.

Valores Mínimos (V.MIN): El valor finito más pequeño dentro de la señal en un período dado.

Curtosis (CUR): Describe el grado de concentración de los valores en torno a la media de una distribución, indicando si la curva es más puntiaguda (alta curtosis) o aplanada (baja curtosis).

Entropía Espectral (E.E.): Mide el grado de impredecibilidad y complejidad en una señal, útil para evaluar cambios en la actividad cerebral.

Entropía Wavelet (E.W.): Cuantifica la asimetría, el desequilibrio y la incertidumbre en una señal, integrando la descomposición por *wavelets* con la entropía para evaluar el nivel de organización o caos.

3. Selección de Características

La selección de características es el paso final en esta fase, donde se eligen las variables más adecuadas para el entrenamiento del modelo de clasificación basándose en su comportamiento. Para ello, se realizaron pruebas para determinar si las características eran **paramétricas o no paramétricas**. Una característica se considera **paramétrica** si cumple con tres condiciones:

1. **Gaussiana:** Se verifica con el **Test de Kolmogorov-Smirnov**. Un valor ρ (p-value) inferior a 0.05 indica que los datos siguen una distribución normal (gaussiana).
2. **Homocedástica:** Se evalúa con el **Test de Levene**. Un valor ρ (p-value) superior a 0.05 concluye que las varianzas no son significativamente diferentes entre sí, cumpliendo el supuesto de homogeneidad.
3. **Independientes:** En este estudio, se asumió la independencia de las variables.

Para características paramétricas: Si los datos cumplen con las tres condiciones, se utiliza el **Test T de Student**. Esta prueba compara las medias de dos grupos y, si el valor ρ es menor a 0.05, determina qué características son más relevantes para el entrenamiento del modelo.

Para características no paramétricas: Si los datos no cumplen las condiciones para ser paramétricos, se recurre al **Test de Wilcoxon**. Esta prueba no

paramétrica también proporciona un valor ρ que señala cuáles características son las más adecuadas para el modelo de clasificación.

Este proceso de selección es crucial para **mejorar la precisión y exactitud del modelo** al entrenarlo con los atributos más informativos.

Resumen Breve

Este estudio presenta una metodología para clasificar dimensiones emocionales en adultos mayores mediante análisis de señales EEG inducidas por estímulos musicales. Se enfocó en la excitabilidad debido a limitaciones en los datos de valencia. El procesamiento incluyó filtrado de ruido, extracción de 11 características y selección estadística de variables relevantes. Utilizando regresión logística, se obtuvieron precisiones del 85.73% y 88.31% para características paramétricas y no paramétricas respectivamente, con capacidades discriminativas superiores al 92% en ambos casos. La metodología demuestra la viabilidad de usar EEG para detectar estados emocionales inducidos por música en población adulta mayor.

Chatgpt:

Aquí tienes una versión revisada, más clara, profesional y resumida del texto original, respetando su estructura y contenido esencial:

Resumen del Estudio

Objetivo principal: Este estudio busca clasificar las dimensiones emocionales inducidas por estímulos musicales en adultos mayores, utilizando señales de electroencefalografía (EEG) y técnicas de aprendizaje automático. Se enfocó particularmente en la **excitabilidad**, ya que la clasificación de la **valencia** se vio limitada por la falta de datos.

Procesamiento de señales: Se aplicaron distintas etapas de preprocesamiento para optimizar las señales EEG, incluyendo **filtrado de ruido** (normalización, eliminación de *offset* y de interferencia de red), **extracción de 11 características** (diez analizadas en tres segmentos y una de asimetría), y **selección**

de **características relevantes** mediante pruebas estadísticas como **Kolmogorov-Smirnov** y **Levene**.

Etiquetado y base de datos: Las etiquetas de excitabilidad (alta/baja) fueron asignadas mediante la prueba **Self-Assessment Manikin (SAM)** posterior a los estímulos musicales. La base de datos inicial incluyó siete ensayos, pero se aplicaron criterios de exclusión rigurosos para asegurar la calidad del conjunto final.

Modelado y validación: Se utilizó un modelo de **regresión logística**, evaluado con **matrices de confusión** y **área bajo la curva ROC (AUC)**.

Resultados clave:

- **Precisión:** 85.73% para características paramétricas, 88.31% para no paramétricas, y 57.39% para asimetría no paramétrica.
 - **AUC:** 92.66% (paramétricas), 94.58% (no paramétricas), y 59.13% (asimetría no paramétrica).
-

Procesamiento de Señales (Resumen Detallado)

El procesamiento de señales EEG fue esencial para identificar patrones relevantes y eliminar artefactos no cerebrales. Este proceso incluyó tres fases principales:

1. Preprocesamiento

Se eliminaron interferencias mediante:

- **Normalización:** Escalado de los datos al rango [0,1] para estandarizar su análisis.
- **Filtro CAR (Common Average Reference):** Eliminación del *offset* y mejora de la relación señal-ruido.
- **Filtro Notch:** Supresión del ruido de red (60 Hz) mediante *iirnotch* y *filtfilt* en MATLAB.

2. Extracción de Características

Se extrajeron 11 características por segmento:

- **Del dominio temporal y espectral:** Media, varianza, desviación estándar, valores extremos, sesgo, curtosis, entropías (diferencial, espectral y wavelet).
- **Asimetría:** Diferencias interhemisféricas calculadas a partir de la densidad espectral de potencia.

3. Selección de Características

Las variables se clasificaron en **paramétricas** o **no paramétricas** con base en:

- **Test de Kolmogorov-Smirnov** (normalidad)
- **Test de Levene** (homocedasticidad)
- Independencia (asumida)

Posteriormente:

- **Características paramétricas:** Analizadas con **Test T de Student**.
- **Características no paramétricas:** Evaluadas con **Test de Wilcoxon**.

Este proceso permitió seleccionar únicamente las características más relevantes, optimizando la precisión del modelo de clasificación.

NotebookLM:

Aquí tiene una revisión del resumen del texto, con un lenguaje más claro y profesional, destacando las ideas clave y manteniendo las citas apropiadas:

Resumen del Estudio

- **Propósito y Enfoque:** El estudio se propuso la **clasificación de dimensiones emocionales** a partir de señales de **electroencefalografía (EEG)** en **adultos mayores**, específicamente aquellas inducidas por **estímulos musicales**, mediante el uso de técnicas de **aprendizaje automático**. La investigación se focalizó en la **excitabilidad**, dado que la clasificación de la **valencia** presentó una dificultad considerable debido a la **escasez de datos disponibles**.
- **Procesamiento de Señales EEG:** Para optimizar la calidad de las señales EEG, se implementaron diversas etapas de procesamiento. Esto incluyó un **filtrado exhaustivo para eliminar ruido irrelevante**:
 - **Normalización:** Estandarización de los datos mediante el escalado de valores a un rango predefinido (mínimos y máximos).
 - **Referencia Común Promedio (CAR):** Eliminación del *offset* y atenuación de artefactos comunes (como movimientos oculares o actividad muscular) para mejorar la relación señal-ruido.

- **Filtro Notch:** Supresión selectiva de frecuencias de ruido específicas, como la **interferencia de la red eléctrica a 60Hz**.
- **Extracción y Selección de Características:** Tras el pre-procesamiento, se llevó a cabo la **extracción de 11 características distintivas** de las señales EEG. Las primeras diez características se aplicaron a tres segmentos de la señal, generando **30 constantes**. La undécima característica, la **asimetría**, proporcionó **15 constantes adicionales** a partir de cinco valores por cada segmento. Posteriormente, se realizó una **rigurosa selección de características relevantes** mediante pruebas estadísticas como **Kolmogorov-Smirnov** (para verificar la distribución gaussiana) y **Levene** (para evaluar la homocedasticidad). Dependiendo de si las características eran paramétricas o no, se utilizaron el **Test T de Student** o el **Test de Wilcoxon** para identificar las más adecuadas para el entrenamiento del modelo.
- **Etiquetado de Datos y Base de Datos:** Las etiquetas de excitabilidad (**alta o baja**) se determinaron a través de la prueba **Self-Assessment Manikin (SAM)**, administrada a los participantes después de la exposición a los estímulos musicales. La base de datos original constaba de 7 ensayos de adultos mayores, pero se aplicaron **criterios estrictos de exclusión y reorganización de datos** para garantizar la robustez del conjunto final, lo que llevó a la exclusión de algunos participantes y la reorganización de los segmentos de prueba.
- **Modelado y Rendimiento:** Se empleó un **modelo de clasificación de regresión logística** para la clasificación de la excitabilidad. El rendimiento del modelo se evaluó rigurosamente utilizando **matrices de confusión** y el **Área Bajo la Curva ROC (AUC)**. Los resultados del entrenamiento fueron prometedores:
 - Para las **características paramétricas**, se logró una **precisión del 85.73%** y una capacidad discriminativa (AUC) del **92.66%**.
 - En el caso de las **características no paramétricas** (sin asimetría), la **precisión fue del 88.31%** y la capacidad discriminativa del **94.58%**.
 - Para la **asimetría no paramétrica**, la **precisión fue del 57.39%** y el AUC del **59.13%**, indicando un área de posible mejora. La **entropía**

diferencial se identificó como una característica paramétrica de suma importancia debido a su alta repetibilidad.